IT Essentials

Theorie 02: Character encoding

AP HOGESCHOOL ANTWERPEN

AP.BE

Hoe tekst voorstellen?

- Tekst is reeks van karakters
- Elke karakter mappen op een getal
- Getal in tabel opzoeken om symbool te tekenen

IT Essentials

ASCII

AP HOGESCHOOL ANTWERPEN

AP.BE

ASCII

Gestandardiseerd in 1969

ASCII

7 bits per karakter

ASCII

2^7 = 128 mogelijke symbolen

ASCII

33 controle codes

- NUL
- BEL
- TAB
- ...

ASCII

95 printbare karakters

- 0-9
- a-z
- A-Z
- ...

ASCII

Beperkt aantal karakters

Extended ASCII

- 1 Byte = 8 bits
- Alle 8 gebruiken → 2^8 = 256 symbolen

ASCII control characters

00	NULL	(Null character)
01	SOH	(Start of Header)
02	STX	(Start of Text)
03	ETX	(End of Text)
04	EOT	(End of Trans.)
05	ENQ	(Enquiry)
06	ACK	(Acknowledgement)
07	BEL	(Bell)
08	BS	(Backspace)
09	HT	(Horizontal Tab)
10	LF	(Line feed)
11	VT	(Vertical Tab)
12	FF	(Form feed)
13	CR	(Carriage return)
14	SO	(Shift Out)
15	SI	(Shift In)
16	DLE	(Data link escape)
17	DC1	(Device control 1)
18	DC2	(Device control 2)
19	DC3	(Device control 3)
20	DC4	(Device control 4)
21	NAK	(Negative acknowl.)
22	SYN	(Synchronous idle)
23	ETB	(End of trans. block)
24	CAN	(Cancel)
25	EM	(End of medium)
26	SUB	(Substitute)
27	ESC	(Escape)
28	FS	(File separator)
29	GS	(Group separator)
30	RS	(Record separator)
31	US	(Unit separator)
127	DEL	(Delete)

ASCII printable characters

32	space	64	@	96	`
33	!	65	A	97	a
34	"	66	B	98	b
35	#	67	C	99	c
36	$	68	D	100	d
37	%	69	E	101	e
38	&	70	F	102	f
39	'	71	G	103	g
40	(	72	H	104	h
41	)	73	I	105	i
42	*	74	J	106	j
43	+	75	K	107	k
44	,	76	L	108	l
45	-	77	M	109	m
46	.	78	N	110	n
47	/	79	O	111	o
48	0	80	P	112	p
49	1	81	Q	113	q
50	2	82	R	114	r
51	3	83	S	115	s
52	4	84	T	116	t
53	5	85	U	117	u
54	6	86	V	118	v
55	7	87	W	119	w
56	8	88	X	120	x
57	9	89	Y	121	y
58	:	90	Z	122	z
59	;	91	[	123	{
60	<	92	\	124	|
61	=	93	]	125	}
62	>	94	^	126	~
63	?	95	_		

Extended ASCII characters

128	Ç	160	á	192	└	224	Ó
129	ü	161	í	193	┴	225	ß
130	é	162	ó	194	┬	226	Ô
131	â	163	ú	195	├	227	Ò
132	ä	164	ñ	196	─	228	õ
133	à	165	Ñ	197	┼	229	Õ
134	å	166	ª	198	ã	230	µ
135	ç	167	º	199	Ã	231	þ
136	ê	168	¿	200	╚	232	Þ
137	ë	169	®	201	╔	233	Ú
138	è	170	¬	202	╩	234	Û
139	ï	171	½	203	╦	235	Ù
140	î	172	¼	204	╠	236	ý
141	ì	173	¡	205	═	237	Ý
142	Ä	174	«	206	╬	238	¯
143	Å	175	»	207	¤	239	´
144	É	176	░	208	ð	240	≡
145	æ	177	▒	209	Ð	241	±
146	Æ	178	▓	210	Ê	242	‗
147	ô	179	│	211	Ë	243	¾
148	ö	180	┤	212	È	244	¶
149	ò	181	Á	213	ı	245	§
150	û	182	Â	214	Í	246	÷
151	ù	183	À	215	Î	247	¸
152	ÿ	184	©	216	Ï	248	°
153	Ö	185	╣	217	┘	249	¨
154	Ü	186	║	218	┌	250	·
155	ø	187	╗	219	█	251	¹
156	£	188	╝	220	▄	252	³
157	Ø	189	¢	221	¦	253	²
158	×	190	¥	222	Ì	254	■
159	ƒ	191	┐	223	▀	255	nbsp

Extended ASCII

- Nog altijd heel beperkt
- Geen ondersteuning voor talen met andere karakterset

IT Essentials

Unicode

AP HOGESCHOOL ANTWERPEN

AP.BE

Unicode

Alle (grote) taalsystemen ondersteunen

Unicode

Uitbreidbaar tot 1.1 miljoen karakters

Unicode

- Onderhouden door Unicode Consortium
- Ondertussen versie 15.1

Unicode

https://en.wikipedia.org/wiki/List_of_Unicode_characters

- 149.813 karakters
- 161 taalsystemen
- 1000-en emoji

Unicode

Hoe encoderen?

Unicode

Lookup table zoals bij ASCII

Unicode

1.1 miljoen karakters → 21 bits nodig

Unicode

Integer types

- 8 bit → te klein
- 16 bit → te klein
- 32 bit → ok
- 64 bit → te groot

UTF-32

Gebruik 32-bit integers

- Elke symbool 4 bytes vs ASCII 1 byte
- 11 van de 32 bits nooit gebruikt

→ plaatsverspeling

IT Essentials

UTF-8

AP HOGESCHOOL ANTWERPEN

AP.BE

UTF-8

Variable-length character encoding

UTF-8

Eerste implementatie in 1992

UTF-8

Meest gebruikte encodering op internet (98%)

UTF-8

Eerste 128 karakters zijn hetzelfde als bij ASCII

UTF-8

First code point	Last code point	Byte 1	Byte 2	Byte 3	Byte 4
U+0000	U+007F	0xxxxxxx			
U+0080	U+07FF	110xxxxx	10xxxxxx		
U+0800	U+FFFF	1110xxxx	10xxxxxx	10xxxxxx	
U+10000	U+10FFFF	11110xxx	10xxxxxx	10xxxxxx	10xxxxxx

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken
   - Vb. Euroteken is U+20AC

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken (U+20AC)
2. Hoeveel bytes zijn er nodig?

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken (U+20AC)
2. Hoeveel bytes zijn er nodig?
   - U+20AC ligt tussen U+0800 en U+20FF
   - Dus 3 bytes nodig

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken (U+20AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. Omzetten codepoint naar binair

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken (U+20AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. Omzetten codepoint → binair
   - 0x20AC = 0b0010’0000’1010’1100

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken (U+20AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. Omzetten codepoint → binair (0010’0000’1010’1100)
4. Invullen codepoint bits in x-jes van UTF-8 bytes

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken (U+20AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. Omzetten codepoint → binair (0010’0000’1010’1100)
4. Invullen codepoint bits in x-jes van UTF-8 bytes
   - 1110xxxx 10xxxxxx 10xxxxxx
   - 11100010 10000010 10101100

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken (U+20AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. Omzetten codepoint → binair (0010’0000’1010’1100)
4. Invullen codepoint bits in x-jes van UTF-8 bytes (11100010 10000010 10101100)
5. UTF-8 bytes omzetten naar hexadecimaal

Unicode codepoint → UTF-8

1. Unicode codepoint van karakter opzoeken (U+20AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. Omzetten codepoint → binair (0010’0000’1010’1100)
4. Invullen codepoint bits in x-jes van UTF-8 bytes (11100010 10000010 10101100)
5. UTF-8 bytes omzetten naar hexadecimaal
   - Per 4 bitjes hex waarde opzoeken in tabel
   - 0xE282AC

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig?

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig?
   - 1 byte = 2 hex digits
   - E2 82 AC → 3 bytes

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. UTF-8 waarde omzetten naar binair

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. UTF-8 waarde omzetten naar binair
   - Per hex digit de 4 bitjes opzoeken in tabel
   - 11100010 10000010 10101100

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. UTF-8 waarde omzetten naar binair (11100010 10000010 10101100)
4. Codepoint bits aflezen op plaats van x-jes in UTF-8

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. UTF-8 waarde omzetten naar binair (11100010 10000010 10101100)
4. Codepoint bits aflezen op plaats van x-jes in UTF-8
   - 1110xxxx 10xxxxxx 10xxxxxx
   - 11100010 10000010 10101100
   - 0010’0000’1010’1100

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. UTF-8 waarde omzetten naar binair (11100010 10000010 10101100)
4. Codepoint bits aflezen op plaats van x-jes in UTF-8 (0010’0000’1010’1100)
5. Codepoint bits omzetten naar hex

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. UTF-8 waarde omzetten naar binair (11100010 10000010 10101100)
4. Codepoint bits aflezen op plaats van x-jes in UTF-8 (0010’0000’1010’1100)
5. Codepoint bits omzetten naar hex
   - Per 4 bits hex digit opzoeken in tabel
   - U+20AC

UTF-8 → Unicode codepoint

1. Start met UTF-8 codepoint (vb. 0xE282AC)
2. Hoeveel bytes zijn er nodig? (3 bytes)
3. UTF-8 waarde omzetten naar binair (11100010 10000010 10101100)
4. Codepoint bits aflezen op plaats van x-jes in UTF-8 (0010’0000’1010’1100)
5. Codepoint bits omzetten naar hex (U+20AC)
6. Karakter in Unicode tabel opzoeken (euroteken)

IT Essentials

Oefeningen UTF-8

AP HOGESCHOOL ANTWERPEN

AP.BE

Oefeningen UTF-8

Unicode CP → UTF-8

- U+0024
- U+0418
- U+10348
- U+2825F

UTF-8 → Unicode CP

- 0x6E
- 0xC2A3
- 0xED959C
- 0xE0A4B9

IT Essentials

Nog vragen?

AP HOGESCHOOL ANTWERPEN

AP.BE